1. Implementation Details

313551176 王駿睿

A. Unet 架構模型

本次實作先建構了一個元件 CC（2 次 conv），有別於原始 Unet 的捲積單位，本次實作對於 2 次的捲積中，將 channel 的數量做漸進式遞增或遞減，避免突然大量流失資訊，另外本次實作了參數 feature=[64,128,256,512]，其中[64,128,256,512]代表 Unet 整體架構中每一層的通道數量，而 Unet 最底部 bottleneck 的通道數量為 feature[-1] * 2，此例子中就是 1024，並可以透過增加 feature 的數量，來增加 Unet 模型的深度。

B. Resnet34_Unet

本次實作延續 CC 元件，額外增加 Resnet34 架構中的殘差捲積元件 BasicBlock，在 encoder 中所有架構和 channel 數量皆和 Resnet34 相同，decoder 和 skip 的操作參考 Lab2 敘述中的圖片架構。

C. 訓練過程

loss 函數採用 dice loss，其值為 1 - dice score，此設計希望 training 和 validation 所要達成的目標一致。optimizer 使用 Adam，並使用 scheduler 調控 learning rate，在一定 epoch 過後 lr 下降一定比例，並加上 early stop 機制，當模型的 validation loss 沒有明顯下降，會自動停止訓練。

D. utils

a. EarlyStopping:

參數 patience，當 validation loss 超過固定 epochs 沒有改善，就中斷訓練。

參數 min_delta，作為 validation loss 最小需改善的量。

參數 path，模型暫存路徑。

b. dice_score:

epsilon 為 0.1，避免除以 0，可支援多筆

資料，返還 dice score 的平均值。

c. dice_loss:

和 dice_score 對應，回傳 1-dice_score。

d. check_loss_line:

給訓練過程中的 train loss 和 validation loss，顯示訓練 loss 曲線圖。

2. Data Preprocessing

在觀察資料當中，有發現有些照片有浮水印的標籤，以及些許的簽名，甚至有些圖片還有一些噪點，但是這些照片的邊界都非常清晰明確。對於這些和模型預測無關或不穩定的因素，本次有實作將資料先經過標準化、低通濾波器、去除陰影，抹平雜訊的干擾和將浮水印與背景融合減少下圖發生機率

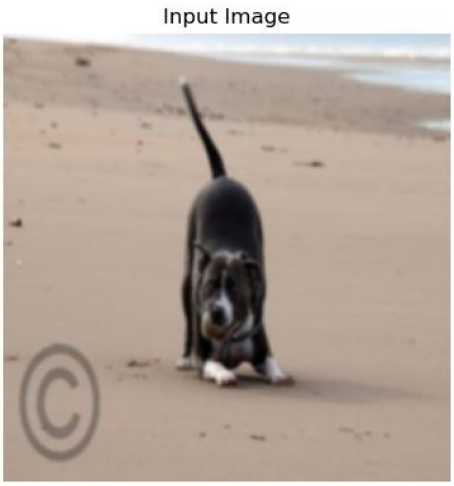

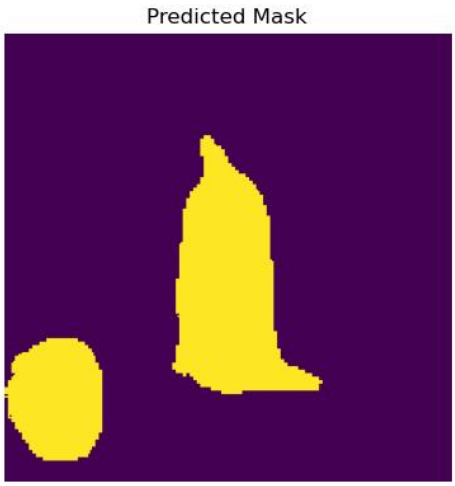

除此之外也有把 training data 做資料擴增，每次取 data 時，會有 50%的機率將照片左右翻轉，以增加資料的多樣性。

(沒有做上下翻轉是因為資料分布不太會有照片上下顛倒的情況)

3. Analyze the experiment results

總體來說 Unet 和 Resnet34_unet 收斂後最佳表現皆落在 dice loss < 0.1 中，也就是 dice score > 0.9

所有的實驗圖片數據皆在./src/result 當中

A. Unet

a. feature layer

測試 Unet 整體架構的深度影響

```
criterion = utils.dice_loss
optimizer = optim.Adam(model.parameters(), lr=1e-3)
scheduler = torch.optim.lr_scheduler.StepLR(optimizer, step_size=12, gamma=0.6)
early_stopping = utils.EarlyStopping(patience=7, min_delta=0.001, path=path)
```

I. feature = [4, 8, 16, 32]

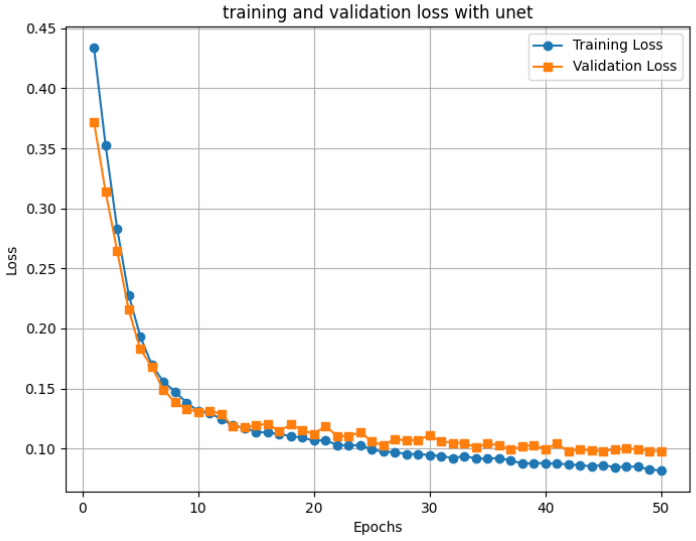


```
Epoch 46/50, Loss: 0.12441837042570114
        Evaluate Dice Loss: 0.12750633557637533
Epoch 47/50, Loss: 0.12508989583987457
        Evaluate Dice Loss: 0.128219872713089
Early stopping...
```

II. feature = [64, 128, 256, 512]

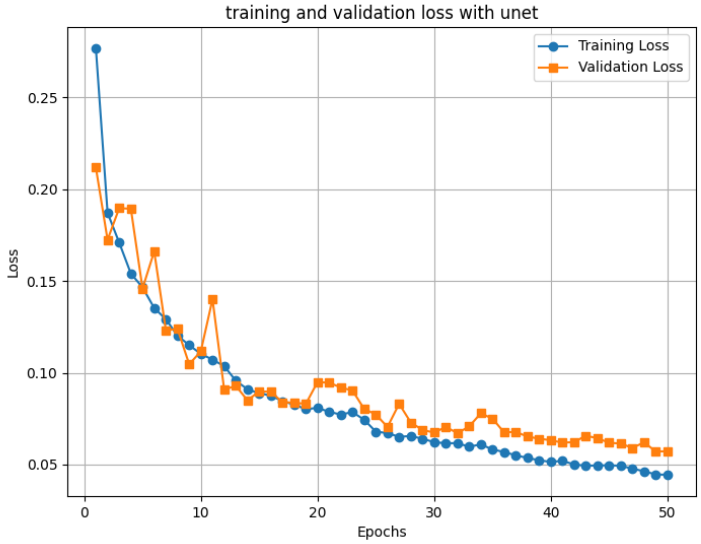

III. little conclusion

架構越深代表模型能夠掌握更多數據，又因為 Unet 的特性，不會因為架構變深而遺忘先前資訊。

B. Resnet34_unet

a. learning rate

測試 lr 對模型收斂的影響

```
criterion = utils.dice_loss
optimizer = optim.Adam(model.parameters(), lr=1e-3)
scheduler = torch.optim.lr_scheduler.StepLR(optimizer, step_size=12, gamma=0.7)
early_stopping = utils.EarlyStopping(patience=10, min_delta=0.001, path=path)
```

I. lr=1e-2

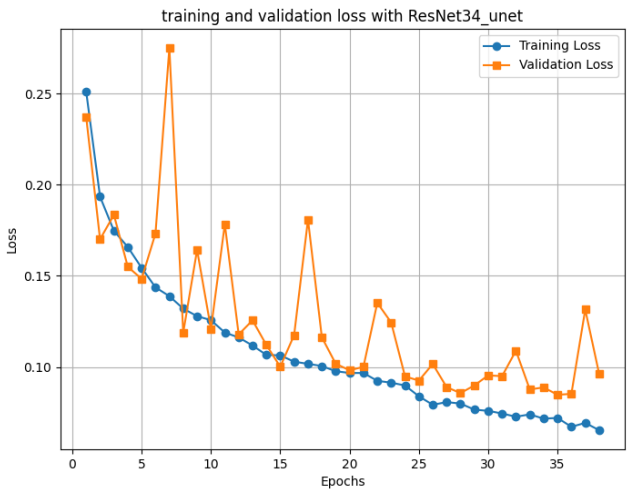

II. lr=1e-3

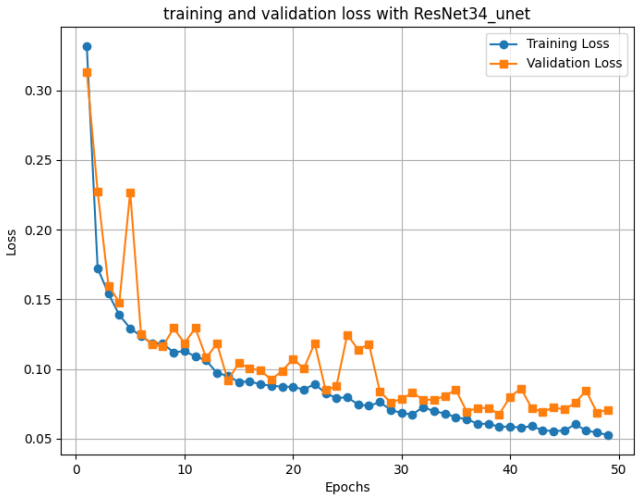

III. lr=1e-4

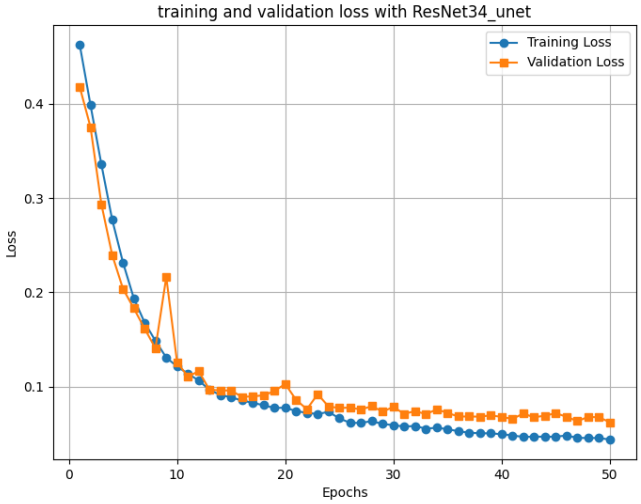

IV. little conclusion

可以發現越小的 lr 模型越趨於穩定，validation loss 的震盪也越小。

C. 其餘的單一實驗

a. 去掉陰影

在觀察模型的 inference，發現有些有陰影

的情況模型不好預測，因此在做資料前處理的時候多加上了一層 remove_shadow 避免干擾，結果 dice score 沒有明顯提升，反而造成了寫許 overfitting。

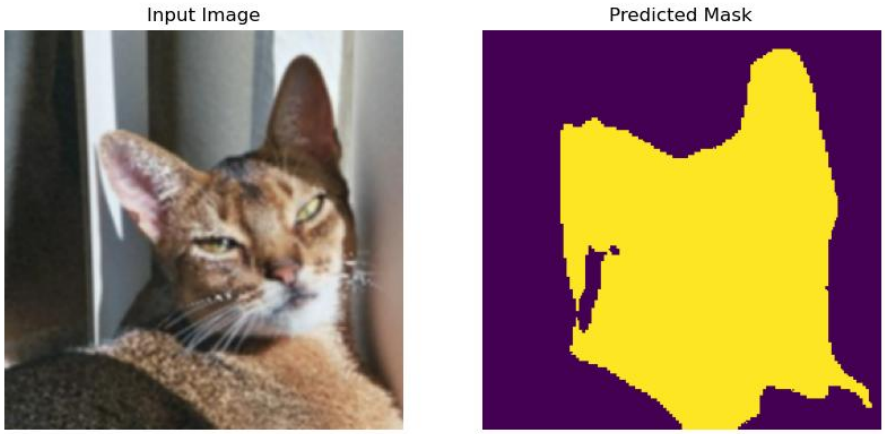

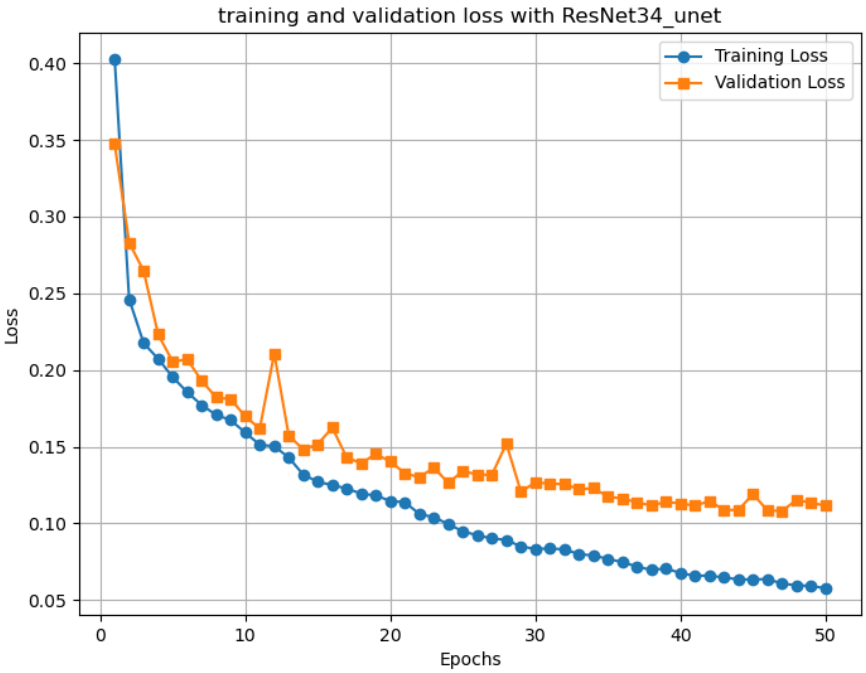

4. Execution steps

A. 環境：以下皆在 linux 上運行

```
python -m venv env
source env/bin/activate
python -m pip install --upgrade pip
pip install -r requirements.txt --extra-index-url
https://download.pytorch.org/whl/cu124
(cu124 為 cuda 版本，根據硬體替換)
```

B. Training

```
訓練 Unet:  python ./src/train.py -m 0
訓練 ResNet34_unet: python ./src/train.py -m 1
```

C. Inference

```
Unet: python ./src/inference.py -m 0 --
model ./saved_models/unet.pth
ResNet34_unet: python ./src/inference.py -m 1 --
model ./saved_models/ResNet34_unet.pth
```

5. Discussion

當模型進行計算時，U-Net 的核心設計就是在於保留先前圖片的資訊。如果是需要在圖片上標記區塊的任務，若僅使用一般 CNN，特徵經過多層 CNN 處理後可能已經和原始圖片相差甚遠，導致無法很好標記。而 U-Net 透過 Skip Connections，將 encoder 中對應層的特徵直接傳遞到 decoder，這樣可以補充該層先前計算的細節，確保模型在慢慢恢復原始圖片大小的過程中仍能保有完整的空間資訊，而提升標記能

力。而論文中也有佐證說 U-Net 架構下對於像是醫學方面，不僅只需要少量數據即可訓練，推理速度也相較為快速(512x512 可以在 1 秒內完成)。

reference: https://arxiv.org/abs/1505.04597